

# Aprendizado de Máquina II

## Redes Bayesianas

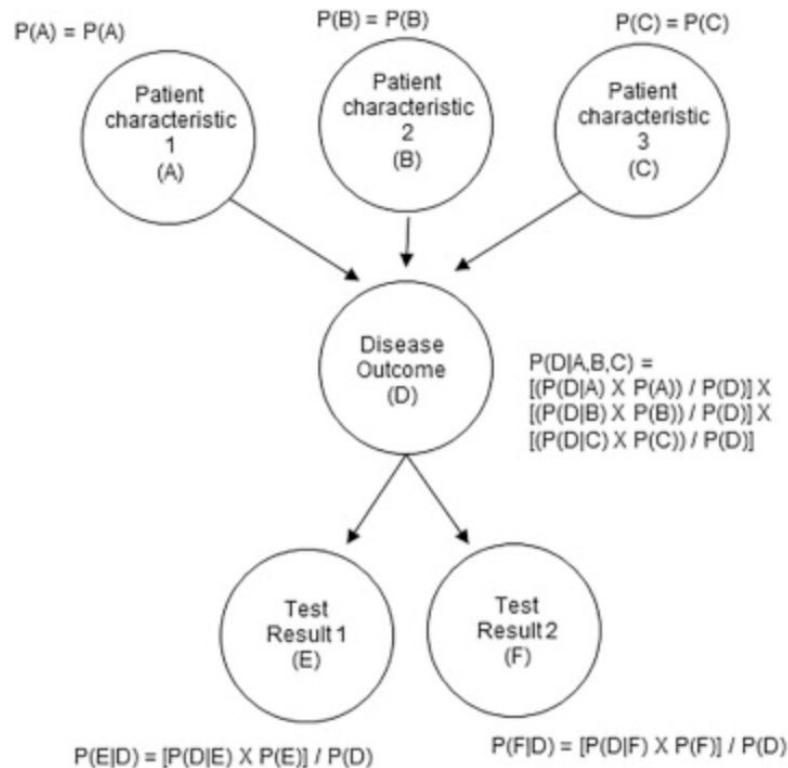


Prof<sup>a</sup>. Carine Webber

Especialização em Ciência de Dados

**2024**

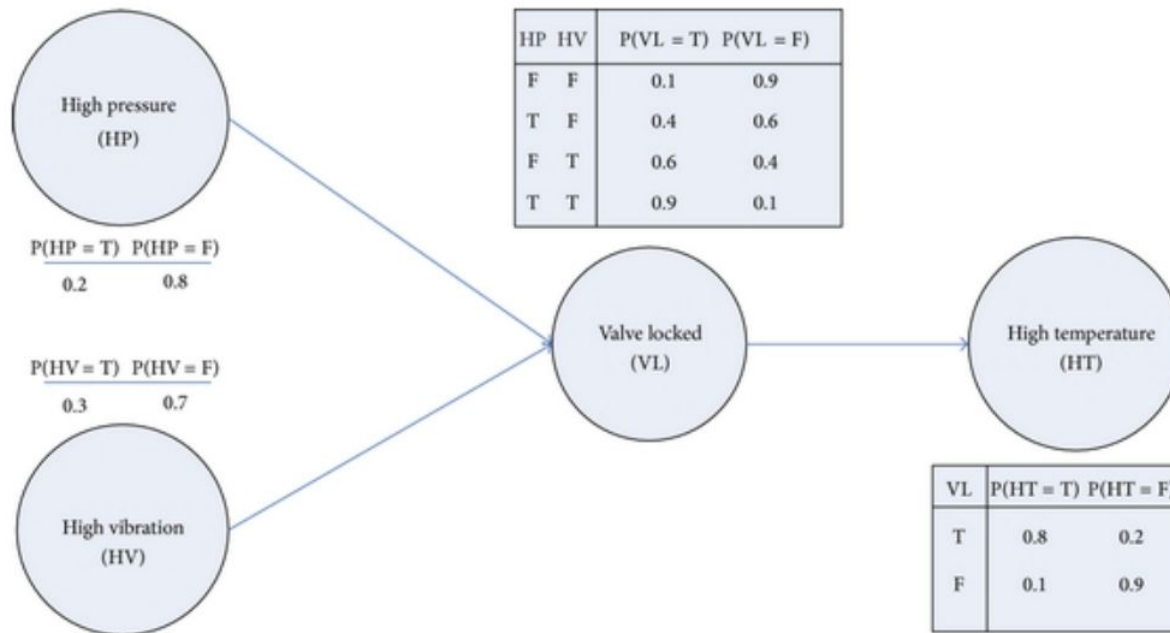
# Exemplo na Medicina



[https://www.valueinhealthjournal.com/article/S1098-3015\(19\)30057-9/fulltext](https://www.valueinhealthjournal.com/article/S1098-3015(19)30057-9/fulltext)


# Exemplo na Engenharia

<https://www.hindawi.com/journals/mpe/2014/210714/>






# Roteiro da Aula

- Teoria das Probabilidades
- Teorema de Bayes
- Aprendizagem Bayesiana
- Implementação no ScikitLearn
- Avaliação do desempenho
- Atividades



# Teoria das Probabilidades

- Desenvolvida no séc. XVIII por Thomas Bayes.
- Idéia principal: entender a frequência com que eventos ocorrem e raciocinar sobre a frequência de futuras combinações de eventos.



# Teorema de Bayes

- **Definição:**

O Teorema de Bayes é uma fórmula matemática que nos permite calcular a probabilidade de um evento com base em informações condicionais.

- **Fórmula:**

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- **Explicação:**

- $P(A|B)$ : Probabilidade de  $A$  dado que  $B$  ocorreu.
- $P(B|A)$ : Probabilidade de  $B$  dado que  $A$  ocorreu.
- $P(A)$ : Probabilidade de  $A$  (a priori).
- $P(B)$ : Probabilidade de  $B$  (a priori).

- **Por que é útil?**

Ele ajuda a atualizar nossas crenças com base em novas evidências.

# Exemplo

## Problema:

Um teste detecta uma doença com:

- 95% de acertos para quem está doente ( $P(Pos|D) = 0.95$ ).
- 5% de falsos positivos ( $P(Pos|\neg D) = 0.05$ ).
- Apenas 1% da população está doente ( $P(D) = 0.01$ ).

**Pergunta:** Se o teste der positivo, qual a probabilidade de a pessoa estar realmente doente ( $P(D|Pos)$ )?

## Solução com o Teorema de Bayes:

1. Aplique a fórmula:

$$P(D|Pos) = \frac{P(Pos|D)P(D)}{P(Pos)}$$

2. Calcule  $P(Pos)$ :

$$P(Pos) = P(Pos|D)P(D) + P(Pos|\neg D)P(\neg D)$$

3. Substitua os valores e descubra a resposta ( $P(D|Pos)$ ).

# Demonstração do Raciocínio

1. Cálculo de  $P(Pos)$ :

$$P(Pos) = P(Pos|D)P(D) + P(Pos|\neg D)P(\neg D)$$

Substituindo os valores:

$$P(Pos) = (0.95 \cdot 0.01) + (0.05 \cdot 0.99) = 0.059$$

2. Cálculo de  $P(D|Pos)$ :

$$P(D|Pos) = \frac{P(Pos|D)P(D)}{P(Pos)}$$

Substituindo os valores:

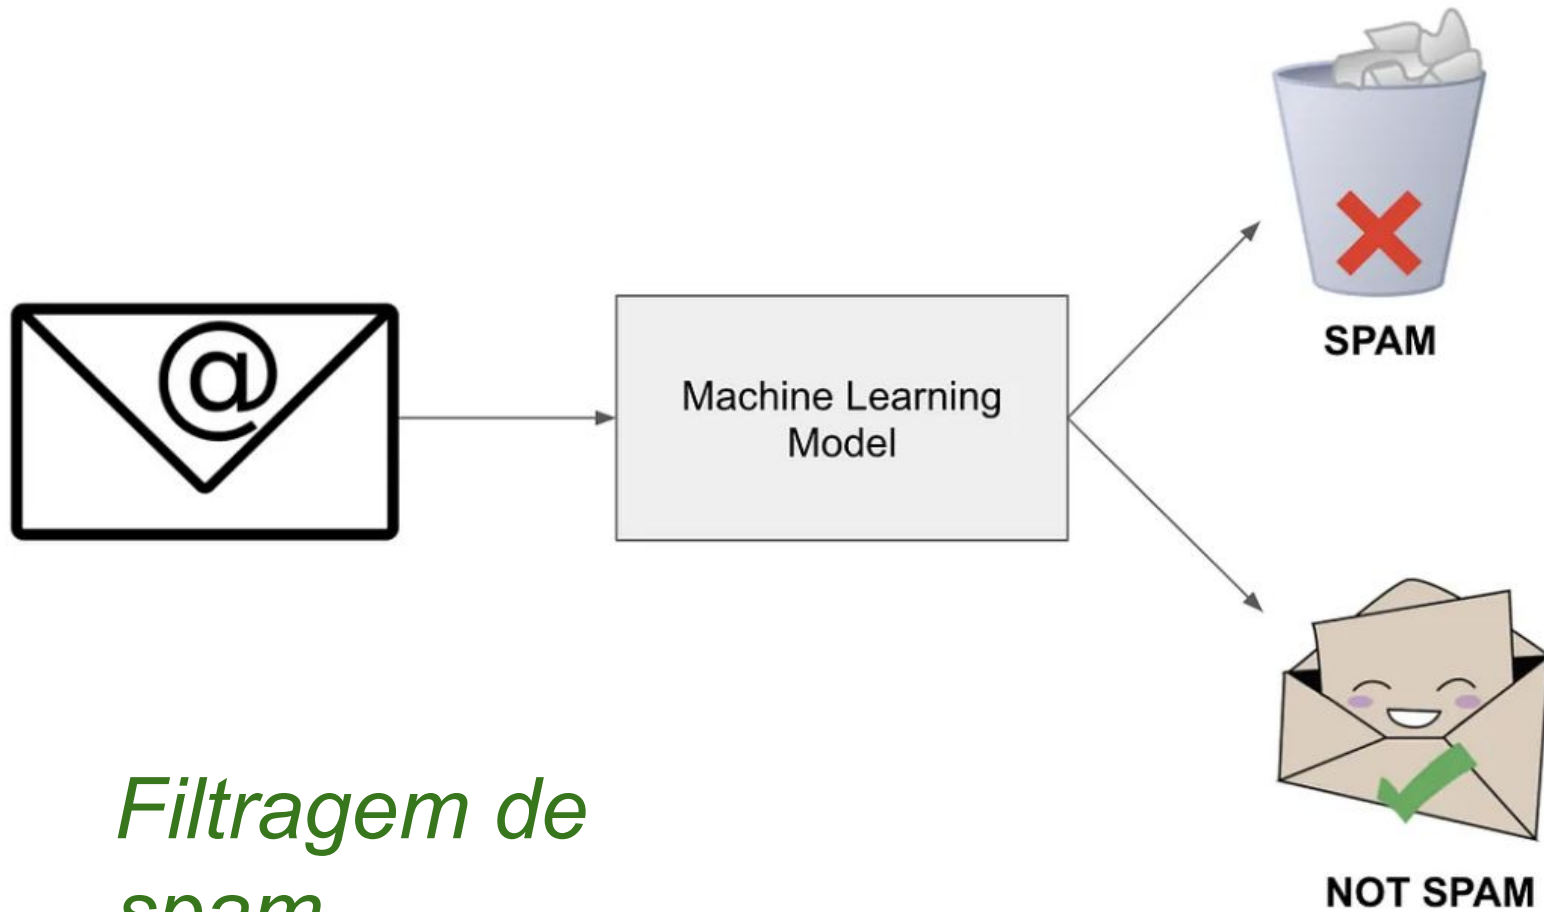
$$P(D|Pos) = \frac{0.95 \cdot 0.01}{0.059} \approx 0.161$$

**Resultados Finais:**

- $P(Pos) = 0.059$  (ou seja, a probabilidade de um teste positivo).
- $P(D|Pos) \approx 16.1\%$  (a probabilidade de estar realmente doente dado que o teste foi positivo).

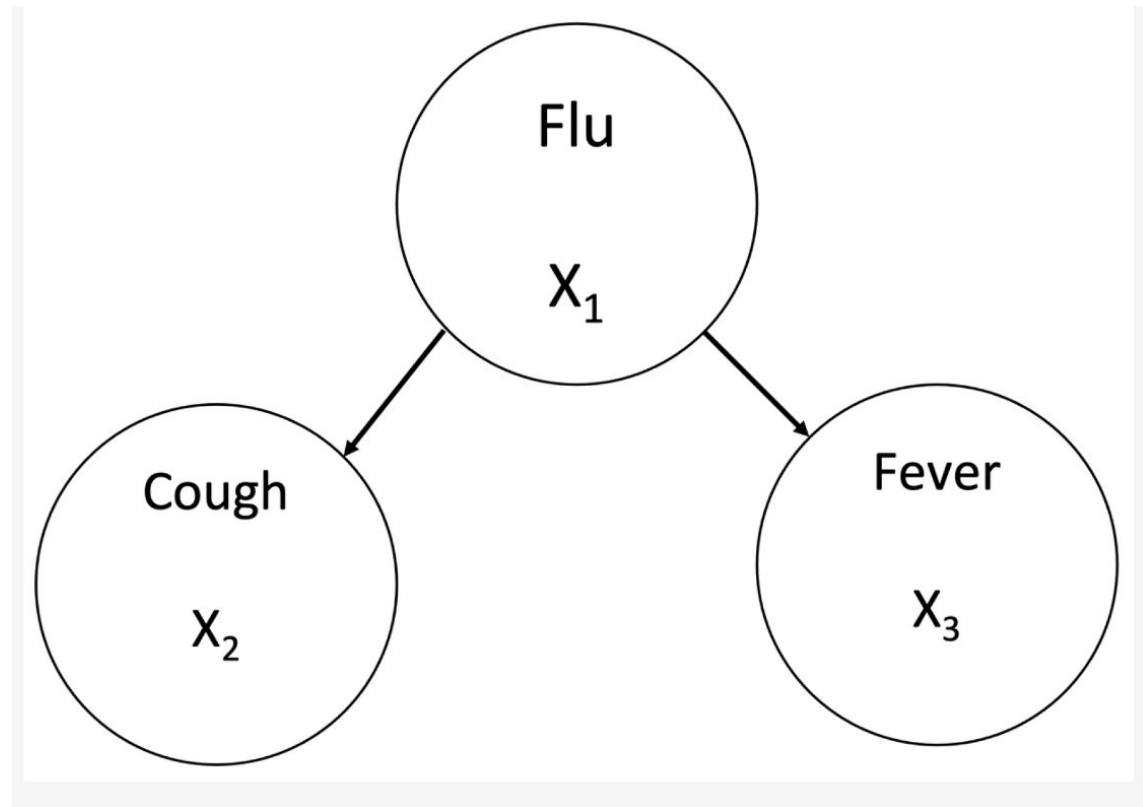


# Exemplos



# Exemplos

## Diagnóstico médico



# Raciocínio Bayesiano

■ Teorema de Bayes: 
$$P(H|E) = \frac{P(E|H) \cdot P(H)}{P(E)}$$

■ Onde:

- $P(H | E)$  é a probabilidade que H seja verdade dada a evidência E;
- $P(E | H)$  é a probabilidade de se observar a evidência E, quando H é verdadeira;
- $P(H)$  é a probabilidade que H seja verdadeira de modo global;
- $P(E)$  é um

fator de  
normalização:

$$P(E) = P(E|H) \cdot P(H) + P(E|\neg H) \cdot P(\neg H)$$

# Raciocínio Bayesiano

- Exemplo:

- $H = \text{"João tem malária"}; E = \text{"João tem febre alta"}$

$$P(malaria|febre) = \frac{P(febre|malaria) \cdot P(malaria)}{P(febre)}$$

$$P(febre) = P(febre|malaria) \cdot P(malaria) + P(febre|\neg malaria) \cdot P(\neg malaria)$$

# Raciocínio Bayesiano

## Exemplo:

- Supõe-se:  $P(malaria) = 0.0001$   
 $P(febre|malaria) = 0.75$   
 $P(febre|\neg malaria) = 0.14$

$$P(febre) = (0.75)(0.0001) + (0.14)(0.9999) \approx 0.14006$$

$$P(malaria|febre) = \frac{(0.75)(0.0001)}{0.14006} \approx 0.0005354$$

# Aplicação da Regra de Bayes: Diagnóstico Médico



Seja

M=doença meningite

S= rigidez no  
pescoço

- Um médico sabe:

$$P(S/M)=0.5$$

$$P(M)=1/50000$$

$$P(S)=1/20$$



$$P(M/S)=\frac{P(S/M)P(M)}{P(S)}$$

$$=\frac{0,5*(1/50000)}{1/20}=0,002$$

A probabilidade de uma pessoa ter meningite dado que ela está com rigidez no pescoço é 0,02% (1 em 5000).

# Teoria das Probabilidades

Distribuição de probabilidades:

	DorDeDente		¬DorDeDente	
	Choque	¬Choque	Choque	¬Choque
Cárie	0.108	0.012	0.072	0.008
¬Cárie	0.016	0.064	0.144	0.576

$$\begin{aligned} P(Cárie | DorDeDente) &= \frac{P(Cárie \wedge DorDeDente)}{P(DorDeDente)} \\ &= \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} = 0.6 \end{aligned}$$

# Teoria das Probabilidades

## ■ Probabilidade Incondicional (a *priori*):

- Grau de confiança associada a uma proposição na ausência de qualquer outra informação.
- Utilizada somente quando não existem outras informações.
- $P(\textit{Tempo}=\textit{ensolarado}) = 0.7$
- $P(\textit{Tempo}=\textit{chuvoso}) = 0.2$
- $P(\textit{Tempo}=\textit{frio}) = 0.08$
- $P(\textit{Tempo}=\textit{neve}) = 0.02$



# Teoria das Probabilidades

## ■ Probabilidade Condicional (a *posteriori*):

- $P(\text{evento}|\text{evidência})$  = "a probabilidade de evento, dado que tudo que se conhece é a evidência."
- Teorema de Bayes para uma doença e um sintoma:

$$P(d|s) = \frac{P(s|d) P(d)}{P(s)}$$

# Método Naive Bayes ou Bayesiano Ingênuo

- **O que é?**

O Naive Bayes é um algoritmo baseado no Teorema de Bayes, com a suposição de que as variáveis são **condicionalmente independentes**.

- **Como funciona?**

Ele calcula a probabilidade de cada classe ( $C_k$ ) e escolhe a mais provável dado um conjunto de características  $(x_1, x_2, \dots, x_n)$ .

- **Por que 'Naive'?**

A palavra "ingênuo" (naive) refere-se à suposição simplificadora de que todas as variáveis são independentes.

# Fórmula geral Naive Bayes

Para classificar uma instância com características  $x_1, x_2, \dots, x_n$ :

$$P(C_k|x_1, x_2, \dots, x_n) \propto P(C_k) \prod_{i=1}^n P(x_i|C_k)$$

**Passos básicos:**

1. **Probabilidade da classe:** Calcular  $P(C_k)$ .
2. **Probabilidade condicional:** Calcular  $P(x_i|C_k)$  para cada característica.
3. **Multiplicação:** Combinar as probabilidades e determinar a maior.

*(A força do Naive Bayes está em sua simplicidade e eficiência.)*

# Implementação no Scikit Learn

- **Definição:**

Um algoritmo probabilístico baseado no teorema de Bayes, assumindo independência condicional entre as características.

- **Principais Tipos no scikit-learn:**

1. `GaussianNB` : Para dados contínuos (assume distribuição normal).
2. `MultinomialNB` : Para dados discretos (e.g., contagem de palavras em NLP).
3. `BernoulliNB` : Para dados binários ou booleanos.
4. `ComplementNB` : Variante do `MultinomialNB` para lidar com desbalanceamento.
5. `CategoricalNB` : Para variáveis categóricas.

- **Vantagens:** Simples, rápido e eficaz para classificações básicas.

- **Limitações:** Assunção de independência condicional nem sempre é realista.

# GaussianNB

- **Quando Usar:**
  - Para **dados contínuos** que seguem (ou aproximadamente seguem) uma **distribuição normal (gaussiana)**.
  - Exemplos:
    - Previsão de notas de alunos com base em idade, horas de estudo, etc.
    - Classificação de espécies com base em medições contínuas, como o dataset Iris.
- **Características:**
  - Calcula probabilidades condicionais assumindo uma distribuição normal para cada característica.
  - Pode ser usado em problemas onde as variáveis não seguem exatamente uma distribuição normal, mas funciona melhor se a suposição for razoável.
- **Hiperparâmetro Principal:**
  - `var_smoothing` : Um pequeno valor é adicionado à variância para evitar problemas numéricos com variâncias próximas de zero.

# Hiperparâmetros GaussianNB

## 2.1 GaussianNB

- `var_smoothing` :
  - **Descrição:** Fração adicionada à variância de cada característica para melhorar a estabilidade numérica.
  - **Valor padrão:** `1e-9` .
  - **Impacto:** Valores maiores suavizam os cálculos, prevenindo divisões por zero em dados com variâncias muito pequenas.

# MultinomialNB

- **Quando Usar:**
  - Para **dados discretos**, como contagens ou frequências.
  - Exemplos:
    - Problemas de **classificação de texto** (como spam ou análise de sentimentos).
    - Modelagem de ocorrências, como número de cliques em anúncios online.
- **Características:**
  - Assume que as características são contagens ou valores positivos.
  - Ideal para **Bag-of-Words** ou **TF-IDF** em problemas de NLP.
- **Hiperparâmetros Principais:**
  - `alpha` : Suavização de Laplace para evitar probabilidades zero (valor padrão: 1.0).
  - `fit_prior` : Define se as probabilidades a priori devem ser aprendidas dos dados.

# Hiperparâmetros

## 2.2 MultinomialNB

- `alpha` :
  - **Descrição:** Parâmetro de suavização de Laplace/Lidstone.
  - **Valor padrão:** `1.0` .
  - **Impacto:** Evita probabilidades zero para palavras ausentes no treinamento (em problemas de texto, por exemplo).
  - **Observação:** Valores menores podem levar a overfitting.
- `fit_prior` :
  - **Descrição:** Define se as probabilidades a priori devem ser aprendidas dos dados ou assumidas uniformes.
  - **Valor padrão:** `True` .
  - **Impacto:** Desabilitar ( `False` ) pode ser útil para classes equilibradas.



# BernoulliNB

- **Quando Usar:**
  - Para **dados binários** (0 ou 1) ou quando as características podem ser tratadas como presença/ausência.
  - Exemplos:
    - Classificação de texto com indicadores binários (se uma palavra aparece ou não em um documento).
    - Dados booleanos em diagnósticos médicos.
- **Características:**
  - Funciona como uma versão binária do MultinomialNB.
  - Útil quando você quer diferenciar entre presença/ausência, em vez de frequências.
- **Hiperparâmetros Principais:**
  - `alpha` : Suavização de Laplace.
  - `binarize` : Define o limiar para binarizar os valores das características. Exemplo:  
*binarize* = 0.5 transforma todos os valores  $> 0.5$  em 1 e  $\leq 0.5$  em 0.

# Hiperparâmetros

## 2.3 BernoulliNB

- `alpha` :
  - Igual ao `MultinomialNB`.
- `binarize` :
  - **Descrição:** Limite usado para binarizar as características (valores maiores que este limite serão tratados como 1, e menores ou iguais, como 0).
  - **Valor padrão:** `0.0`.
  - **Impacto:** Importante para dados que não são binários por natureza. Um valor de `None` desabilita a binarização.
- `fit_prior` :
  - Igual ao `MultinomialNB`.

# ComplementNB

- **Quando Usar:**
  - Uma variante do MultinomialNB para lidar com **dados desbalanceados**.
  - Exemplos:
    - Classificação de texto quando algumas classes têm muitos mais exemplos do que outras.
- **Características:**
  - Calcula probabilidades complementares, priorizando classes menos representadas.
  - Melhora a precisão em classes minoritárias sem prejudicar classes majoritárias.
- **Hiperparâmetros Principais:**
  - `alpha` : Suavização.
  - `norm` : Se as probabilidades complementares devem ser normalizadas (valor padrão: True).

# Hiperparâmetros

## 2.4 ComplementNB

- `alpha` :
  - Igual ao `MultinomialNB`.
- `norm` :
  - **Descrição:** Se as probabilidades complementares devem ser normalizadas.
  - **Valor padrão:** `True`.
  - **Impacto:** Normalização ajuda a evitar problemas de escala.

## 2.5 CategoricalNB

- `alpha` :
  - Igual ao `MultinomialNB`.

# CategoricalNB

- **Quando Usar:**
  - Para **variáveis categóricas** em vez de contínuas ou discretas.
  - Exemplos:
    - Classificação de clientes com base em atributos categóricos como "idade", "localização" e "preferências".
- **Características:**
  - Trata cada característica como uma categoria nominal.
  - Requer que os dados sejam pré-processados em categorias ou rótulos numéricos.
- **Hiperparâmetros Principais:**
  - `alpha` : Suavização.

# Hiperparâmetros

Modelo	Hiperparâmetro	Descrição	Valor Padrão
GaussianNB	var_smoothing	Fração adicionada à variância	1e-9
MultinomialNB	alpha	Suavização de Laplace	1.0
	fit_prior	Considerar probabilidades a priori	True
BernoulliNB	alpha	Suavização de Laplace	1.0
	binarize	Limite para binarização das características	0.0
	fit_prior	Considerar probabilidades a priori	True
ComplementNB	alpha	Suavização de Laplace	1.0
	norm	Normalizar probabilidades complementares	True
CategoricalNB	alpha	Suavização de Laplace	1.0

# Redes Bayesianas

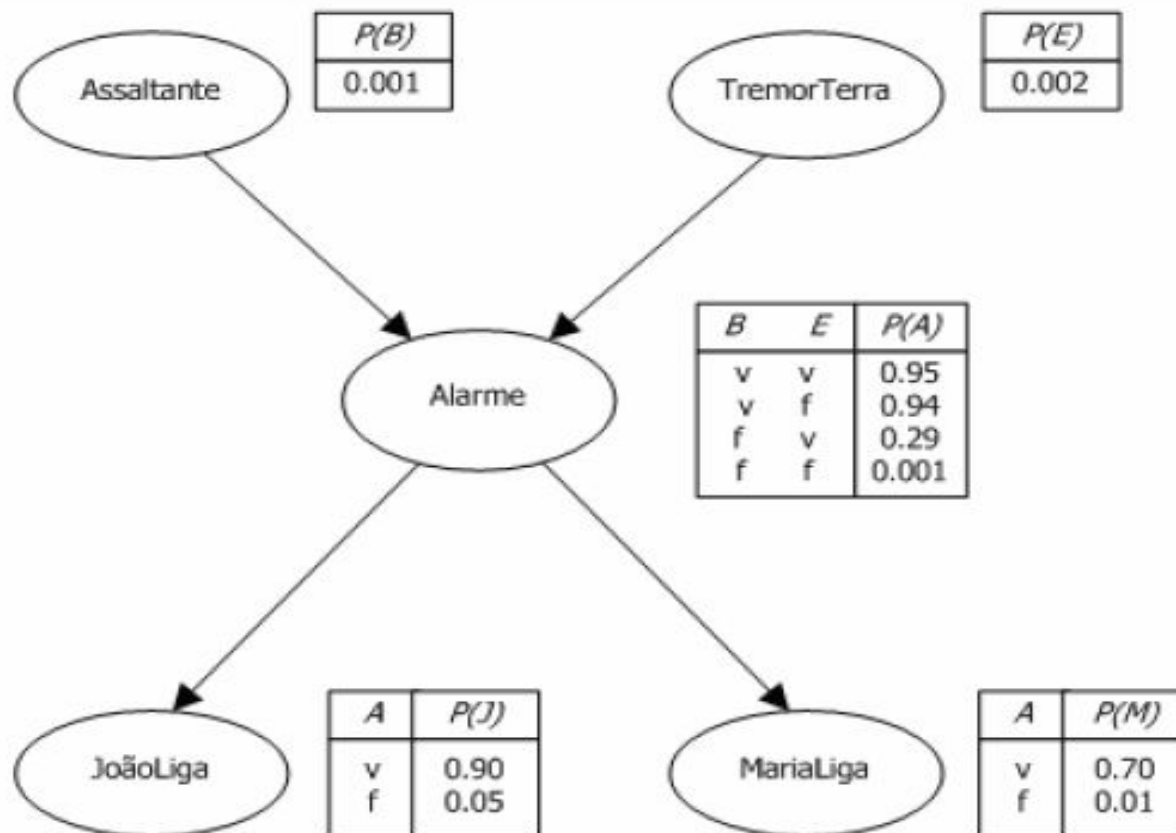
- RB foram introduzidas por Judea Pearl (1988).
- RB surgiram como um método para lidar com informações incertas e probabilísticas.
- RB foram geradas do casamento entre a Teoria das Probabilidades e a Teoria dos Grafos.
- Aplica-se a problemas que envolvam processos de decisão, tais como classificação, reconhecimento de padrões, reconhecimento de sequencias, direcionamento de robôs, modelagem de CAD, dentre outras.
- Exemplo: Softwares de filtragem de SPAMS.

# Redes Bayesianas

- Um conjunto de variáveis representadas por nós;
- Um conjunto de setas conectando pares de nós.
  - Um nó  $X$  é dito pai de  $Y$ , se existe uma seta com origem em  $X$  e chegada em  $Y$ ;
- Cada nó  $X$  possui uma distribuição de probabilidades que quantifica os efeitos dos seus pais sobre este nó;
- Todos os nós e setas devem formar um grafo dirigido acíclico.



# Redes Bayesianas-Exemplo



# Redes Bayesianas-Exemplo

■ Qual a probabilidade de ocorrer a situação em que o alarme tenha tocado (a), mas não ocorreu nem tremor (e) e nem invasão de assaltante (b), e João (j) e Maria (m) ligam para avisar ?

$$P(j \wedge m \wedge a \wedge \neg b \wedge \neg e)$$


$$= P(j|a) \cdot P(m|a) \cdot P(a|\neg b \wedge \neg e) \cdot P(\neg b) \cdot P(\neg e)$$

$$= 0.90 * 0.70 * 0.001 * 0.999 * 0.098 = 0.00062$$

# Aprendizagem de Redes Bayesianas

## Busca e pontuação

- Pontuar as redes candidatas através de uma métrica de pontuação.
- Realizar uma busca heurística para encontrar a estrutura ótima.
- Exemplo:



# Engenharia do conhecimento para Redes Bayesianas

1. Escolher um conjunto de variáveis relevantes que descrevam o domínio
2. Ordem de inclusão dos nós na rede
  - (a). causas como “raízes” da rede
  - (b). variáveis que elas influenciam
  - (c). folhas, que não influenciam diretamente nenhuma outra variável.
3. Enquanto houver variáveis a representar:
  - (a). escolher uma variável  $X_i$  e adicionar um nó para ela na rede
  - (b). estabelecer  $\text{Pais}(X_i)$  dentre os nós que já estão na rede, satisfazendo a propriedade de **dependência condicional**
  - (c). definir a tabela de probabilidade condicional para  $X_i$

# Bibliografia

- Russel, S, & Norvig, P. (1995). Artificial Intelligence: a Modern Approach (AIMA) Prentice-Hall. Pages 436-458, 588-593
- Mitchell, T. & (1997). Machine Learning, McGraw-Hill. Cap.6
- Fayyad et al. (1996). Advances in knowledge discovery and data mining, AAAI Press/MIT Press. Cap.11
- Pearl, J. (1988) Probabilistic Reasoning in Intelligent Systems. San Mateo, CA: Morgan Kauffman.